

UNIVERSIDAD DE LOS ANDES

IDENTIFICACIÓN DE LESIONES CUTÁNEAS DEL TORSO POSTERIOR INFERIOR: UNA APLICACIÓN TÉCNICA DE APRENDIZAJE NO SUPERVISADO

PAOLA ALEXANDRA CIFUENTES
PAOLA VANESSA ALFARO MORA
DANIEL DAVID FLOREZ THOMAS
CAMILO ERNESTO ROBAYO ABELLO

RESUMEN: Mediante el análisis de imágenes de lesiones de piel, se desarrollará un algoritmo de clustering jerárquico aglomerativo para marcar y segmentar las áreas afectadas. Se utilizará una matriz de distancias reducida mediante PCA para realizar un clustering jerárquico. Con la matriz reducida se marcarán las áreas de la lesión cutánea mediante dos técnicas: encontrar el área que contenga un patrón diferente en la fotografía por el promedio de los colores y encontrar dos clústeres (piel sana y piel con lesión) mediante el algoritmo de KMedoides. El análisis se centrará en lesiones del torso posterior inferior. Se extraerá una muestra de 4.596 imágenes de un dataset de 401.059. Los resultados obtenidos permitirán identificar patrones asociados a diferentes tipos de lesiones y contribuirán al desarrollo de una herramienta de apoyo para clasificación de imágenes, facilitando la identificación de alertas tempranas de lesiones cutáneas.

1. INTRODUCCIÓN

Las lesiones cutáneas son un motivo de consulta muy frecuente en las personas. No obstante, hay una parte de la población que desestima la sintomatología asociada a este tipo de enfermedades y no detecta tempranamente los cambios en la piel que puedan alertar de un problema de salud.

Este trabajo se basa en la competencia pública de Kaggle *ISIC 2024 - Skin Cancer Detection with 3D-TBP* la cual tiene como objetivo desarrollar algoritmos para la detección de cáncer de piel, utilizando un dataset de casos confirmados con fotos 3D TBP¹ y que se pueda aplicar a fotos tomadas con un celular para el diagnóstico preliminar.

El cliente potencial de nuestro proyecto incluye tanto la comunidad médica como la población general, ya que se pretende crear una herramienta accesible que permita identificar lesiones en la piel sin la necesidad inmediata de acudir a un médico. Las imágenes están etiquetadas por ejemplo con información demográfica como la edad, tipos de lesión, el sexo y la ubicación de la lesión en el cuerpo, con la cual se podrán identificar patrones relevantes asociados a estas variables.

En cuanto al procesamiento de datos y metodología, primero se estandariza el tamaño de las imágenes a 120x120 píxeles, un paso crucial para los algoritmos posteriores. Luego, transformamos las imágenes a escala de grises y las convertimos en matrices de 14400 columnas por imagen. Debido al gran volumen de datos, implementaremos reducción de dimensionalidad mediante PCA (perteneciente al área de aprendizaje no supervisado, específicamente en la técnica de clustering), análisis del impacto de dicha reducción en los resultados, y segmentación del área afectada

¹ Total Body Photos

utilizando promedios de secciones de cada imagen. El análisis jerárquico nos permitirá capturar las principales características de cada grupo a nivel de edad, sexo y tipo de lesión.

Para la marcación del área afectada se utilizarán los componentes principales de la matriz original y por un análisis de cuadrícula de cada foto, se determinará el área que es diferente al resto de la fotografía. En contraste, se utilizará el algoritmo de KMedoides para que cada cuadrícula sea analizada como una sub-fotografía y el algoritmo encuentre dos clústeres: piel sana y piel con lesión.

Esta temática se encuentra en la literatura y Pioneros como Esteva et al. (2017) los cuales demostraron que con el uso de técnicas de aprendizaje no supervisado y en su caso de estudio las redes neuronales convolucionales pueden alcanzar un nivel de precisión comparable al de dermatólogos expertos en la clasificación de imágenes de lesiones cutáneas.

A partir de este hallazgo inicial, la investigación en el campo ha evolucionado significativamente. Codella et al. (2017), por ejemplo, propusieron el uso de ensambles de modelos de deep learning para mejorar aún más la precisión en la clasificación de melanoma. Esto demuestra la tendencia a combinar múltiples modelos para obtener resultados más robustos.

Otras técnicas de aprendizaje no supervisado, como el clustering, han demostrado su utilidad en la identificación de patrones subyacentes en imágenes de la piel. Codella et al. (2018), en su estudio sobre el ISBI 2017, exploraron en profundidad el potencial de estas técnicas para tareas como segmentación, detección de características y clasificación de enfermedades.

Yu et al. (2017) han profundizado en el diseño de arquitecturas de redes neuronales convolucionales más complejas y profundas, capaces de extraer características más discriminativas. Al combinar estas arquitecturas con técnicas de segmentación precisas, Yu et al. lograron resultados superiores en la clasificación de melanoma.

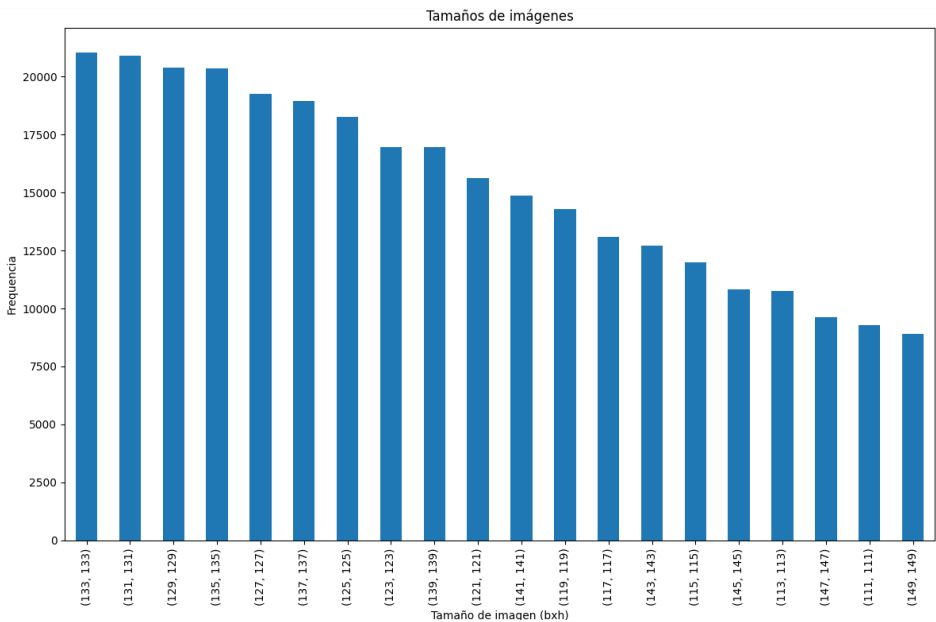
Por otro lado, Zhang et al. (2020) propusieron un enfoque híbrido que combina clustering jerárquico con CNN para identificar patrones subyacentes en las imágenes que son difíciles de detectar con métodos tradicionales. Este enfoque híbrido demuestra la tendencia a combinar diferentes técnicas para abordar la complejidad de la clasificación de lesiones cutáneas.

En este contexto, nuestro proyecto se centra en identificar patrones visuales característicos en imágenes de lesiones cutáneas para diferenciar entre piel sana y piel con lesiones. El enfoque del análisis es antes de los modelos de predicción y diagnóstico. A través de técnicas de clustering jerárquico y aglomerativo, buscamos segmentar las imágenes y agrupar aquellas que presentan características similares. A diferencia de estudios previos que se enfocan principalmente en la clasificación binaria de lesiones malignas y benignas, nuestro enfoque se centra en la identificación de piel sana y piel con lesión segmentando de manera precisa una posible área afectada con lesión. Al utilizar estas técnicas, esperamos desarrollar un modelo que pueda detectar tempranamente áreas de interés en la piel y tener alertas que le permitan a los usuarios acudir oportunamente al médico.

2. DESCRIPCIÓN DE LOS DATOS

Originalmente el dataset de imágenes está compuesto por 401.059 imágenes en formato JPG. Adicionalmente, se tiene un archivo con la metadata donde está la información médica de cada lesión. Las fotografías tienen diferentes tamaños, todas son cuadradas y se caracterizan por estar entre 100 y 150 píxeles en cuanto al tamaño. Como se muestra en la siguiente gráfica y muestra de 10 imágenes:


Ilustración 1. Tamaño de imágenes



Fuente: Elaboración propia, 2024.

Muestra de las imágenes:

Ilustración 2. Muestra de fotografías de las lesiones cutáneas



Fuente: Elaboración propia con imágenes de International Skin Imaging Collaboration 2024.

Vemos que las imágenes tienen gran variedad de lesiones con colores, texturas, formas, ubicaciones y tipos de lesión, lo cual enriquece el análisis para procesar mejores ejemplos de la gran diversidad de lesiones que se pueden encontrar en la piel.

Por otro lado, vemos que la metadata está compuesta por 54 columnas, así:

Ilustración 3. Tipo y descripción de datos

```
<class 'pandas.core.frame.DataFrame'>
Index: 401059 entries, ISIC_0015670 to ISIC_9999967
Data columns (total 54 columns):
#   Column                                     Non-Null Count  Dtype
---  -
0   target                                     401059 non-null  int64
1   patient_id                               401059 non-null  object
2   age_approx                               398261 non-null  float64
3   sex                                       389542 non-null  object
4   anatom_site_general                      395303 non-null  object
5   clin_size_long_diam_mm                  401059 non-null  float64
6   image_type                              401059 non-null  object
7   tbp_tile_type                           401059 non-null  object
8   tbp_lv_A                                 401059 non-null  float64
9   tbp_lv_Aext                             401059 non-null  float64
10  tbp_lv_B                                 401059 non-null  float64
11  tbp_lv_Bext                             401059 non-null  float64
12  tbp_lv_C                                 401059 non-null  float64
13  tbp_lv_Cext                             401059 non-null  float64
14  tbp_lv_H                                 401059 non-null  float64
15  tbp_lv_Hext                             401059 non-null  float64
16  tbp_lv_L                                 401059 non-null  float64
17  tbp_lv_Lext                             401059 non-null  float64
18  tbp_lv_areaMM2                           401059 non-null  float64
19  tbp_lv_area_perim_ratio                  401059 non-null  float64
20  tbp_lv_color_std_mean                    401059 non-null  float64
21  tbp_lv_deltaA                            401059 non-null  float64
22  tbp_lv_deltaB                            401059 non-null  float64
23  tbp_lv_deltaL                            401059 non-null  float64
24  tbp_lv_deltaLB                           401059 non-null  float64
25  tbp_lv_deltaLBnorm                       401059 non-null  float64
26  tbp_lv_eccentricity                      401059 non-null  float64
27  tbp_lv_location                          401059 non-null  object
28  tbp_lv_location_simple                   401059 non-null  object
29  tbp_lv_minorAxisMM                      401059 non-null  float64
30  tbp_lv_nevi_confidence                   401059 non-null  float64
31  tbp_lv_norm_border                       401059 non-null  float64
32  tbp_lv_norm_color                       401059 non-null  float64
33  tbp_lv_perimeterMM                      401059 non-null  float64
34  tbp_lv_radial_color_std_max              401059 non-null  float64
35  tbp_lv_stdL                             401059 non-null  float64
36  tbp_lv_stdLExt                          401059 non-null  float64
37  tbp_lv_symm_2axis                       401059 non-null  float64
38  tbp_lv_symm_2axis_angle                 401059 non-null  int64
39  tbp_lv_x                                 401059 non-null  float64
40  tbp_lv_y                                 401059 non-null  float64
41  tbp_lv_z                                 401059 non-null  float64
42  attribution                             401059 non-null  object
43  copyright_license                       401059 non-null  object
44  lesion_id                               22058 non-null  object
45  iddx_full                               401059 non-null  object
46  iddx_1                                  401059 non-null  object
47  iddx_2                                  1068 non-null  object
48  iddx_3                                  1065 non-null  object
49  iddx_4                                  551 non-null  object
50  iddx_5                                  1 non-null  object
51  mel_mitotic_index                       53 non-null  object
52  mel_thick_mm                            63 non-null  float64
53  tbp_lv_dnn_lesion_confidence             401059 non-null  float64
dtypes: float64(35), int64(2), object(17)
memory usage: 176.4+ MB
```

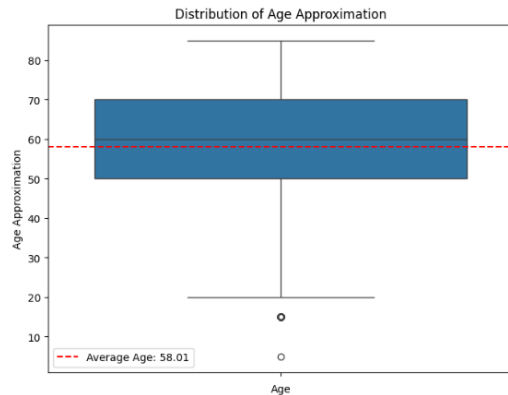
Fuente: Elaboración propia, 2024.

Las columnas incluyen datos como el target, patient_id, age_approx, sex, y características de las imágenes como dimensiones y colores. No obstante, la mayoría de las columnas tienen valores no nulos, y algunas como age_approx, sex, y lesion_id, presentan valores faltantes.

Vemos que los tipos de datos son float64, int64 y object, lo que refleja la diversidad de información en el dataset. Entonces en general se puede ver que algunas columnas no tienen toda la información, lo cual demandará en un procesamiento de datos cuando se vaya a realizar el análisis. El diccionario de la metadata está en el sitio de la competencia.

A continuación, se presenta el análisis descriptivo de las principales columnas de todo el data frame:

Ilustración 4. Distribución por edad



La edad de la población está en un rango entre los 20 y 80 años, con un promedio de 58 años y la mitad de las personas están por debajo de los 60 años. Hay unos pocos casos atípicos por debajo de los 20 años.

Fuente: Elaboración propia, 2024.

Ilustración 5.
Distribución por

sexo

El 68% de las fotografías fueron tomadas a hombres y el restante a mujeres. Por ello vemos que la mayoría son del género masculino.

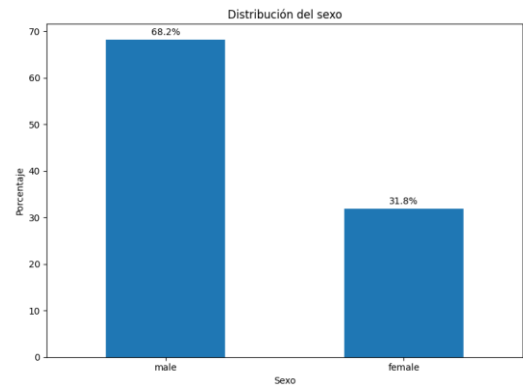
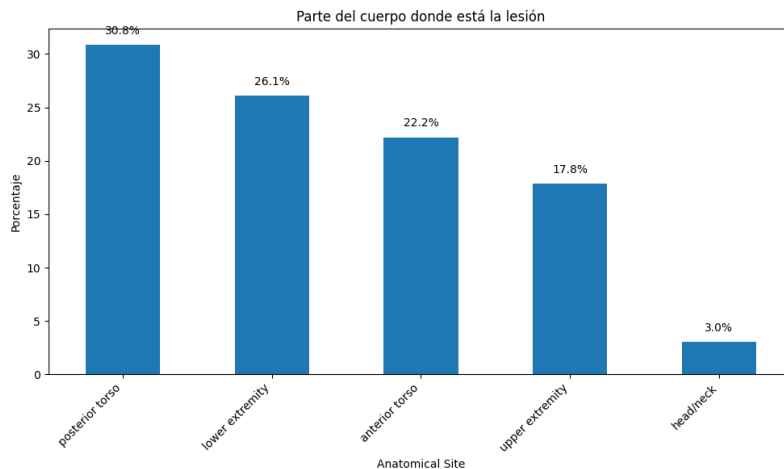


Ilustración 6. Parte del cuerpo donde está la lesión



Fuente: Elaboración propia, 2024.

Las partes del cuerpo donde se tomaron las fotografías son 5. Esta información es importante para la selección de la muestra, la cual se va a concentrar en lesiones de la parte posterior del torso.

Fuente: Elaboración propia, 2024.

2.1 Descripción de los datos en el torso posterior inferior:

La parte del cuerpo seleccionada para este estudio y desarrollo del algoritmo corresponde al torso. El alcance se acotará para casos que se presenten en la parte posterior inferior del torso por ser un número de imágenes conveniente para el alcance de este proyecto por temas de rendimiento y eficiencia de algoritmo a la hora de procesar la información; a continuación, la distribución de lesiones en el torso:

Ilustración 7. Número de imágenes para el torso posterior inferior

El número de imágenes para el torso posterior son: 121902

Para el torso posterior, las imágenes están clasificadas así:

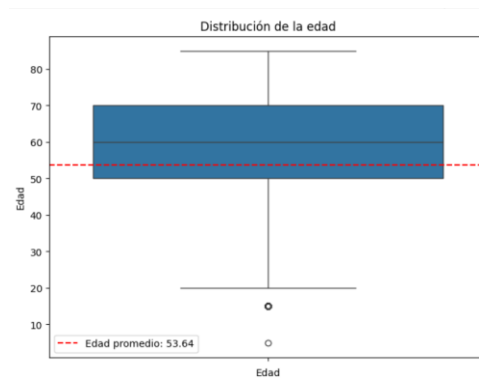
```
tbp_lv_location
Torso Back Top Third      71112
Torso Back Middle Third   46185
Torso Back Bottom Third   4596
Torso Back                9
Name: count, dtype: int64
```

Fuente: Elaboración propia, 2024.

Con respecto a la edad promedio vemos que es 5 años menor a la edad general de toda la base de datos de las más de 400 mil imágenes, y en este caso solo del torso posterior inferior que son 4596 imágenes la edad promedio es 53 años.

Además las personas con lesiones en el torso posterior inferior están dentro del rango de edad entre los 10 y 80 años de edad.

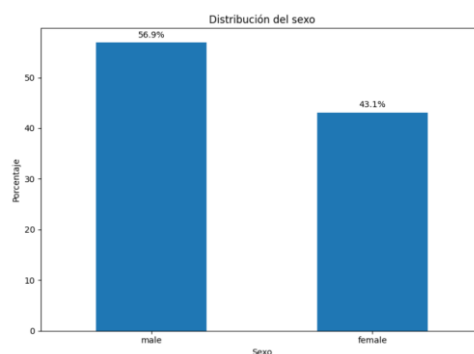
Ilustración 8. Distribución por edad para el torso posterior inferior



Fuente: Elaboración propia, 2024.

Aunado a lo anterior la distribución de género pasa de ser un 43% mujeres y el 57% hombres, siendo una distribución un poco más equitativa en cuanto a sexo con respecto a la distribución general en esta categoría de todas las partes del cuerpo con lesiones.

Ilustración 9. Distribución por sexo para el torso posterior inferior

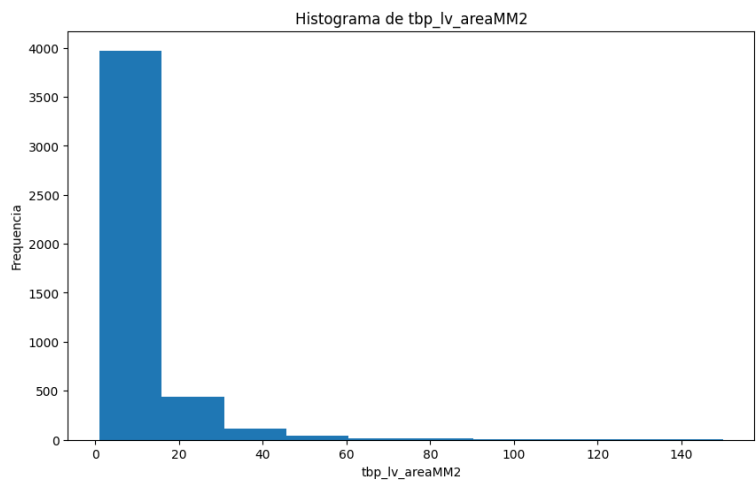


Fuente: Elaboración propia, 2024.

También vemos que la mayoría de lesiones en el torso inferior posterior corresponden a un tamaño de área entre los 0 y 20 mm², lo cual servirá como método de agrupación por clustering jerárquico aglomerativo como característica muy descriptiva del tipo de lesión para uno de los grupos que se detallarán a continuación en la sección de metodología con la muestra de las respectivas imágenes en cada grupo creado.

En detalle vemos que los tamaños de área de las lesiones más frecuentes en esta ubicación son 5.05 mm², 4.65 mm², 4.82 mm² y 4.69 mm². Y los los tamaños menos ocurrentes 16.68 mm², 38.21 mm² y 32.39 mm², que presentan únicamente una vez.

Ilustración 10. Histograma por tamaño de área de la lesión en el torso posterior inferior



Fuente: Elaboración propia, 2024.

3. PROPUESTA METODOLÓGICA

El desarrollo de este proyecto siguió un enfoque estructurado para analizar imágenes de lesiones cutáneas mediante técnicas de aprendizaje no supervisado. La metodología abarcó desde la selección de la muestra, preprocesamiento y reducción de dimensionalidad, hasta la aplicación de algoritmos de clusterización y la visualización de los resultados. A continuación, se detallan los pasos seguidos.

i. Revisión y selección de la muestra


El primer paso fue la revisión y entendimiento de la información disponible en el conjunto de datos, compuesto por más de 400,000 imágenes de lesiones cutáneas. Dado el tamaño del dataset, se realizó una selección de una muestra representativa de aproximadamente 4,596 imágenes, asegurando que tuviera una distribución similar a la muestra total. La muestra seleccionada incluyó imágenes de lesiones en el torso posterior, centradas en casos con características demográficas relevantes, como edad y sexo, para garantizar una representación adecuada de la población.

ii. Limpieza y procesamiento de la información

Una vez seleccionada la muestra, se procedió a la limpieza y procesamiento de los datos. Las imágenes, que varían en tamaño y calidad, fueron normalizadas a un tamaño estándar de 120x120 píxeles, lo que permitió estandarizar la resolución y facilitar los análisis posteriores. Además, las imágenes fueron convertidas a escala de grises, eliminando la información de color que no era relevante para la identificación de las lesiones.

Posteriormente, las imágenes se organizaron en un DataFrame, donde cada fila correspondía a una imagen y cada columna representa un píxel de la imagen, resultando en un conjunto de datos de 14,400 columnas (120x120 píxeles por imagen). Dado el elevado costo computacional de manejar un dataset de esta magnitud, se decidió aplicar una reducción preliminar de dimensionalidad mediante PCA (Análisis de Componentes Principales), reduciendo el número de columnas a 25 componentes principales, los cuales capturan el 95% de la varianza en los datos. La reducción de 14.400 a 25 se puede explicar que las fotografías tienen una configuración homogénea en el sentido que la mayoría tiene la lesión en el centro de la fotografía y la mayoría de píxeles tiene un patrón “constante”.

Ilustración 11. Comparativa de imágenes original versus reconstruida



Fuente: Elaboración propia, 2024.


La precisión de la imagen de la derecha se debe evaluar dependiendo del objetivo del análisis. Para el caso que nos ocupa, el cual es la identificación del área afectada, la precisión es aceptable porque la zona con la lesión ocupa un número similar de píxeles, inclusive detalles en el interior de la lesión.

Sin lugar a dudas, para otros objetivos, como diagnóstico médico, modelos de predicción, entre otros, la pérdida de información puede ser inaceptable.

iii. Procesamiento y análisis de las imágenes

Con el dataset reducido, se aplicaron algoritmos de clusterización para encontrar patrones en las imágenes y agruparlas en función de las características visuales y demográficas. El enfoque principal fue la clusterización jerárquica aglomerativa, que permitió identificar 4 clusters significativos. Estos clusters representaban diferentes tipos de lesiones cutáneas, y cada uno fue caracterizado según sus propiedades visuales:

Ilustración 12. Dendrograma de Clustering Jerárquico



Fuente: Elaboración propia, 2024.

- Cluster 1: Los tonos de piel son más oscuros y la anomalía de la piel no es tan marcada. La calidad de las imágenes es menor y seguramente esto podría ser un criterio para descartar imágenes que no se pueden analizar.
- Cluster 2: Se caracteriza porque tiene varias lesiones en la piel y el área afectada es mucho más grande que los otros clústeres.
- Cluster 3: Se caracteriza por tono de piel clara y el área afectada se resalta fuertemente; adicionalmente se las lesiones tienen una orientación horizontal
- Cluster 4: Es similar al clúster 3 pero la orientación de la lesión es vertical

Ilustración 13. Muestra de 4 clusters representativos de tipos de lesiones




Fuente: Elaboración propia con imágenes de International Skin Imaging Collaboration 2024.

El análisis reveló diferencias demográficas importantes entre los clusters, como una mayor proporción de hombres en los clusters 1 y 2, y una mayor prevalencia de lesiones malignas en los clusters 2 y 3.

iv. Análisis jerárquico

Ilustración 14. Distribución de la Edad por Cluster



Fuente: Elaboración propia, 2024.

Los grupos tienen rangos similares de edades. El clúster uno tiene un promedio más elevado que el resto de clúster

Ilustración 15. Cluster jerarquico por sexo y por tarjet

sex					
Cluster_Jerarquico	sex		target		
1	male	127	2	0	1181
	female	36			
2	male	796	3	0	1889
	female	372			
3	male	1054	4	0	1356
	female	814			
4	female	734	1	1	3
	male	604			

Fuente: Elaboración propia, 2024.

Los clústeres 3 y 4 tienen una distribución similar a la muestra total, donde hombres tiene una participación cercana al 60% y el resto mujeres. Los clústeres 1 y 2 agrupan lesiones que se presentan más en hombres que en mujeres, con una relación 2:1 y 3:1 respectivamente.


Las lesiones de los clústeres 1 y 4 no registran casos positivos, se debe investigar más si las características de estos grupos permiten concluir cuando un caso es benigno. Los clústeres 2 y 3 registran casos positivos. Se resalta la concentración en el cluster pues el porcentaje asciende al 0.25% mientras que la muestra total está en el 0.1%

v. Detección de áreas afectadas

Uno de los objetivos clave de este estudio fue la detección de áreas afectadas dentro de las imágenes de lesiones cutáneas. Para lograr esto, se implementaron dos técnicas de segmentación:

- **Marcación del área afectada por promedio de píxeles:** Se dividieron las imágenes en cuadrículas de 25 x 25 píxeles, y se marcaron las áreas más oscuras (posiblemente lesionadas) mediante el promedio de los valores de los píxeles en cada cuadrícula.

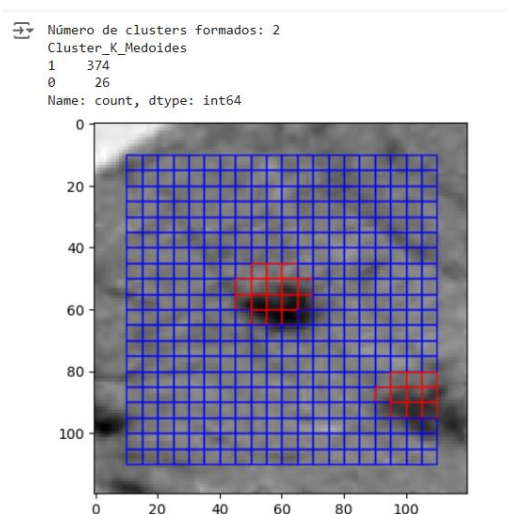
Ilustración 16. Marcación de área afectada por promedio de píxeles



Fuente: Elaboración propia, 2024.

- **Segmentación con K-Medoids:** Se aplicó el algoritmo de K-Medoids para identificar dos clusters dentro de cada imagen (uno para piel sana y otro para la piel lesionada). Esta técnica permite segmentar las imágenes en cuadrículas y etiquetar las posibles áreas de lesión cutánea, aunque su sensibilidad a la configuración de hiper parámetros fue un desafío.

Ilustración 17. Identificador de piel sana y piel afectada Cluster_K_Medoides



Fuente: Elaboración propia, 2024.

v. Interpretación y visualización de los resultados

Los resultados del análisis fueron interpretados a través de la visualización de los clusters y las áreas afectadas. Se superpusieron colores sobre las imágenes para resaltar las zonas lesionadas, utilizando rectángulos para marcar las áreas afectadas por los clusters detectados. Esta visualización permite una identificación clara de las posibles lesiones y ofrece una herramienta útil tanto para el diagnóstico preliminar como para estudios más detallados.

5. RESULTADOS Y DISCUSIÓN

La técnica de clustering es muy eficiente para entender de manera preliminar la organización y jerarquía que tienen grandes volúmenes de datos. Para las imágenes analizadas, algunos grupos presentan fotografías de menor calidad, mientras que otros agrupan lesiones con orientaciones particulares o con múltiples áreas afectadas. Estos resultados nos permiten entender mejor cómo varían las lesiones cutáneas y qué patrones emergen al analizar grandes volúmenes de datos.

Encontramos que este algoritmo es sensible a los hiper parámetros y a la calidad del contraste en la imagen, por lo que no es ideal en todos los casos. A pesar de esto, nuestros métodos permiten capturar áreas afectadas y mejorar la precisión del diagnóstico preliminar.

Una de las principales fortalezas del algoritmo de clustering jerárquico aglomerativo es su capacidad para proporcionar una visión clara de cómo se agrupan las imágenes en función de las distancias calculadas. La naturaleza jerárquica del algoritmo permitió explorar relaciones profundas entre las imágenes, revelando patrones visuales importantes que podrían no ser evidentes con otros métodos.

El K-Medoids utilizado para segmentar áreas afectadas dentro de las imágenes, fue particularmente efectivo al identificar clusters internos (piel sana vs piel lesionada) en cada imagen. Sin embargo, su rendimiento depende en gran medida de la configuración de los hiper parámetros, lo que implica la necesidad de sintonizar el modelo adecuadamente para obtener resultados más precisos y requiere que aplicar previamente una clasificación como la mostrada en el dendrograma.

A nivel de limitaciones, este trabajo destaca la necesidad de mejorar la calidad de las imágenes antes de aplicar los algoritmos de clustering. La dependencia de la calidad y el contraste de las imágenes afecta la precisión de la segmentación. Además, la implementación del clustering jerárquico en grandes conjuntos de datos representa un desafío en términos de escalabilidad, lo que podría requerir la adopción de técnicas más eficientes para conjuntos de datos masivos.

Para estudios futuros, se recomienda explorar la incorporación de características adicionales en los modelos de clustering, como la textura, color y forma de las lesiones, lo que podría enriquecer el análisis. Además, la combinación de técnicas de aprendizaje supervisado y no supervisado puede mejorar la capacidad de los modelos para predecir el tipo de lesión, lo cual podría ser evaluado en futuros estudios clínicos.

6. CONCLUSIONES

En este estudio se desarrolló un enfoque basado en técnicas de aprendizaje no supervisado para la identificación de lesiones cutáneas en imágenes del torso posterior inferior. Utilizando un conjunto de imágenes de más de 400,000 ejemplos, se extrajo una muestra representativa de 4,596 imágenes para su análisis. El proceso comenzó con la estandarización del tamaño de las imágenes y su conversión a escala de grises, seguido de una reducción de dimensionalidad mediante PCA, lo que permitió manejar un conjunto de datos más eficiente y con menor costo computacional.

La clusterización jerárquica aglomerativa identificó cuatro clusters principales, cada uno con características demográficas y visuales distintivas. Los clusters 2 y 3, que mostraban lesiones más grandes y visibles, presentaron una mayor prevalencia de lesiones malignas, mientras que los clusters 1 y 4, con imágenes de menor calidad o lesiones menos visibles, no registraron malignidad. Esta segmentación no solo facilitó la identificación de patrones comunes, sino que también permitió observar la variabilidad en las lesiones cutáneas de manera más precisa.

El estudio logró detectar áreas afectadas mediante dos técnicas complementarias: la segmentación basada en promedios de píxeles y el uso del algoritmo de K-Medoids. Estas técnicas permitieron identificar de manera efectiva las zonas lesionadas dentro de las imágenes, aunque se observó que el algoritmo de K-Medoids es sensible a la configuración de hiper parámetros.

En general, el proyecto demostró que las técnicas de clusterización y reducción de dimensionalidad aplicadas permiten identificar patrones importantes en imágenes médicas, ofreciendo una base sólida para futuros desarrollos en herramientas de diagnóstico asistido. Sin embargo, se recomienda una mayor optimización de los algoritmos para mejorar la precisión en casos de imágenes de menor calidad o lesiones más difíciles de detectar. Además, los resultados sugieren la necesidad de combinar estas técnicas con enfoques supervisados para lograr un diagnóstico más preciso en el ámbito clínico.

7. BIBLIOGRAFÍA

- Codella, N., Nguyen, Q.-B., Pankanti, S., Gutman, D., Helba, B., Halpern, A., & Smith, J. R. (2017). Deep learning ensembles for melanoma recognition in dermoscopy images. *IBM Journal of Research and Development*. Recuperado de : <https://doi.org/10.48550/arXiv.1610.04662>
- International Skin Imaging Collaboration. (2024). *The ISIC 2024 Challenge Dataset: Official training and testing datasets of the ISIC 2024 Challenge*. Recuperado de: <https://doi.org/10.34970/2024-slice-3d>
- Nicholas Kurtansky, Veronica Rotemberg, Maura Gillis, Kivanc Kose, Walter Reade, Ashley Chow. (2024). *ISIC 2024 - Skin Cancer Detection with 3D-TBP*. Recuperado de: <https://kaggle.com/competitions/isic-2024-challenge>
- Yu, L., Chen, H., Dou, Q., Qin, J., & Heng, P.-A. (2017). Automated melanoma recognition in dermoscopy images via very deep residual networks. *IEEE Transactions on Medical Imaging*, Recuperado de: <https://doi.org/10.1109/TMI.2016.2642839>
- Brinker, T. J., Hekler, A., Ittner, C., & Enk, A. H. (2016). Automated melanoma recognition in dermoscopy images: A systematic review. *Journal of the American Academy of Dermatology*, 74(4), 671-682.
- Codella, N. C., Gutman, D., Celebi, M. E., Helba, B., Marchetti, M. A., Dusza, S. W., ... & Halpern, A. (2018, April). Skin lesion analysis toward melanoma detection: A challenge at the 2017 international symposium on biomedical imaging (isbi), hosted by the international skin imaging collaboration (isic). In *2018 IEEE 15th international symposium on biomedical imaging (ISBI 2018)* (pp. 168-172). IEEE. Recuperado de: <https://arxiv.org/pdf/1710.05006>
- Esteva, A., Kuprel, B., Novoa, R. A., Ko, J., Swetter, S. M., Blau, H. M., & Thrun, S. (2017). Dermatologist-level classification of skin cancer with deep neural networks. *nature*, 542(7639), 115-118. Recuperado de: <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC8382232/>
- International Skin Imaging Collaboration. (2024). *The ISIC 2024 Challenge Dataset: Official training and testing datasets of the ISIC 2024 Challenge*. Recuperado de: <https://doi.org/10.34970/2024-slice-3d>
- Kurtansky, N., Rotemberg, V., Gillis, M., Kose, K., Reade, W., & Chow, A. (2024). *ISIC 2024 - Skin Cancer Detection with 3D-TBP*. Recuperado de: <https://kaggle.com/competitions/isic-2024-challenge>
- Tan, T. Y., Zhang, L., & Lim, C. P. (2020). Adaptive melanoma diagnosis using evolving clustering, ensemble and deep neural networks. *Knowledge-Based Systems*, 187, 104807. Recuperado de: <https://www.sciencedirect.com/science/article/abs/pii/S0950705119302825>
- Yu, L., Chen, H., Dou, Q., Qin, J., & Heng, P.-A. (2017). Automated melanoma recognition in dermoscopy images via very deep residual networks. *IEEE Transactions on Medical Imaging*. Recuperado de: <https://doi.org/10.1109/TMI.2016.2642839>